PHYSICAL AI 2026 / FINAL PROJECT

SO-101 実機模倣学習から MuJoCo への Real-to-Sim 移行

実機データ収集・ACT 学習・仮想関節制御・教師軌道比較

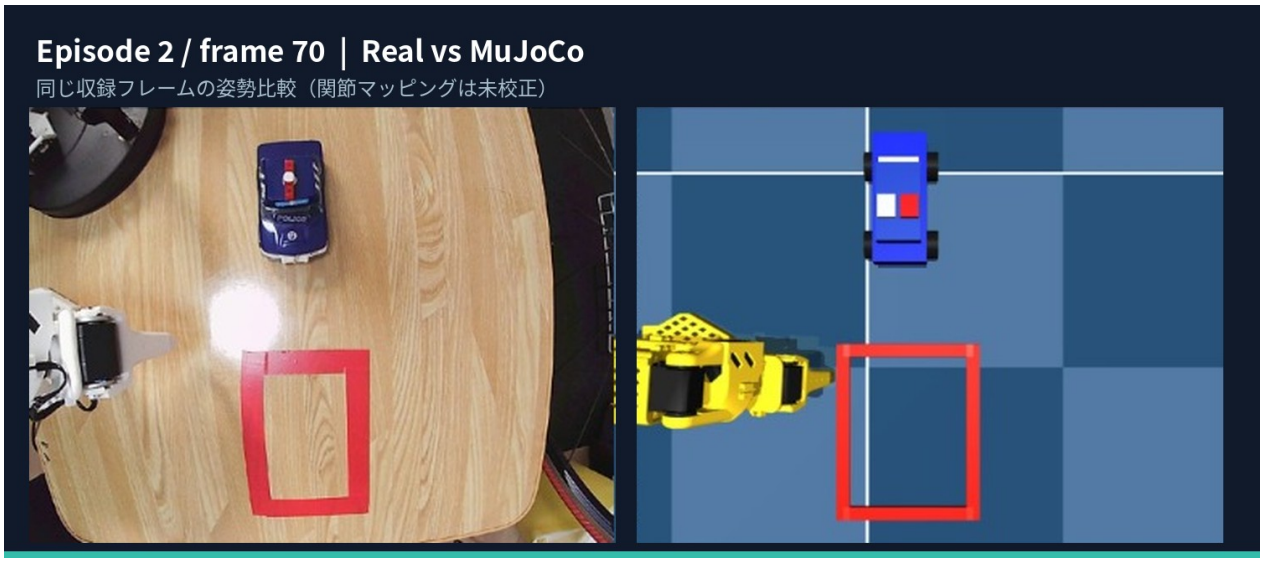


図 1　Episode 2 frame 70 の実機画像と同時刻の MuJoCo 姿勢。配置は目視近似、関節マッピングは未校正。

要旨

実機 SO-101 に対するミニカーの Goal 移動タスクを対象に、LeRobot 形式のテレオペレーションデータを 10 エピソード（4,500 フレーム、15FPS）収集し、ACT モデルを学習した。実機自律制御はハードウェア面の安全上の懸念により見送り、MuJoCo 上に仮想 SO-101 と近似作業環境を構築した。ACT による仮想関節駆動、教師アクションと ACT 予測のオフライン再生、模倣精度と時間特性の評価を実施した。

主な結果：Episode 2 の 450 フレームでは、6,000 ステップ ACT の 5 軸平均 MAE は約 4.13°で、静止ベースライン（約 1.77°）より大きかった（約 2.3 倍）。一方、教師アクションを+9 フレームずらした探索的比較では MAE が 4.262°から 2.923°に低減した。これは時間的先行傾向の手掛かりだが、同期不良や自律タスク成功の証拠ではない。

1. 研究目的と実験条件

研究目的は、実機 SO-101 による「青いミニカーを赤い Goal 枠に移動する」教師操作を記録し、模倣学習と Real-to-Sim によって関節動作の再現可能性を調べることである。

項目	条件
対象ロボット	SO-101（実機）／ MuJoCo SO-101 MJCF
実機タスク	青いミニカーを赤い Goal 枠へ移動
データセット	LeRobot Dataset v3.0、10 エピソード、各 450 フレーム
収録レート	15FPS（合計 4,500 フレーム）
観測	上面カメラ画像（640×480）、6 関節状態
教師出力	6 関節位置アクション
学習モデル	ACT / No-VAE。新規 5,000 step→再開 10,000 step。代表 6,000 step
評価対象	Episode 2（設定上 eval_split=0.2。単一タスク 10 件なら学習側。割当ログは未検証）

採用モデルの学習条件：ACT No-VAE、ResNet18、Transformer 次元 128（Encoder 2 層・Decoder 1 層）、chunk_size=20、バッチサイズ 1、AdamW（学習率 1×10^{-5}、Weight Decay 1×10^{-4}、Gradient Clipping 10.0）。No-VAE で 5,000 ステップまで新規学習し、その保存状態から 10,000 ステップまで再開した。代表モデルは 6,000 ステップである。詳細は付録 A。

2. Real-to-Sim 構成

MuJoCo では 6 軸 SO-101 MJCF を使用し、記録された関節値を仮想モデルへ変換して与えた。仮想作業環境には青いミニカーと赤い Goal 枠を近似配置した。これらは可視化用の静的オブジェクトであり、ミニカーに接触物理は設定していない。

- 教師軌道再生：収録された action 系列を MuJoCo の関節位置目標として再生。
- ACT 予測軌道再生：各教師観測に対する ACT のオフライン予測を MuJoCo に入力し、同じ初期姿勢から比較。
- ACT 実行試験：固定された実写フレームと現在の仮想関節状態を入力し、ACT 推論を各ステップ実行。

注意：オフライン予測の再生は、仮想環境カメラからの観測による自律視覚閉ループではない。

3. 関節マッピングと安全方針

初期の関節マッピング（度→ラジアン、5 軸とも符号+1、オフセット 0）は暫定設定として維持した。上面画像による+15°候補は複数フレーム比較で一貫した改善を確認できず、採用していない。実機のトルクや COM ポートを使う制御は本実験では行わない。グリッパーは仮想環境で固定した。

4. ACT オフライン模倣精度

Episode 2 の全 450 フレームに対し、実機の画像[t]と state[t]を ACT へ入力し、予測の先頭アクションと教師の action[t]を比較した。静止ベースラインは「state[t]をそのまま action として出す」予測である。

関節	ACT MAE	静止 MAE	ACT / 静止
shoulder_pan	4.887°	1.864°	2.62
shoulder_lift	7.502°	2.410°	3.11
elbow_flex	5.497°	2.921°	1.88
wrist_flex	1.977°	1.219°	1.62
wrist_roll	0.773°	0.424°	1.83
5 軸単純平均	4.126°	1.768°	約 2.33

5 関節とも同時刻での MAE は静止ベースラインより大きい。グリッパーは表現単位が異なり、状態値がほぼ一定であるため 5 軸の角度平均から除外した。

チェックポイント比較 (同一 45 サンプル)

checkpoint	5 軸平均 MAE	評価
6,000 steps	4.276°	比較対象で最良
8,000 steps	5.872°	悪化
10,000 steps	4.566°	6,000 より悪い

学習を延長しただけでは教師アクションとの一致は改善しなかった。checkpoint の比較には同じ学習 Episode 2 から stride=10 で採った 45 点を使用し、最終評価 450 点も同じ Episode 2 である。45 点の平均 4.276°と 450 点の平均 4.126°の差はサンプル集合の違いによる。モデルの過学習・データ不足・前処理の不整合などを本結果だけで確定することはできない。

5. 時間特性の診断

420 フレームの共通区間について、ACT 予測[t]と教師指令[t+lag]を比較した。探索した lag は-15〜+15 フレーム（15FPS）。

比較条件	ACT 5 軸平均 MAE	静止ベースライン
同時刻 lag=0	4.262°	1.784°
教師を+9 フレーム	2.923°	5.040°

ACT の最適ラグは+9 フレーム（約 0.60 秒）で、同一時刻比較より MAE が 31.4%小さくなった。関節別最適ラグは+5〜+10 フレーム、3 区間に分けた最適ラグは+7、+10、+10 だった。

同じ未来時刻の教師指令[t+9]との比較では、ACT 2.923°、静止ベースライン 5.040°、直近 5 フレームの関節速度による因果的な線形外挿 3.410°だった。ただし+9 は同じ学習エピソード上で ACT の MAE が最小となるよう事後選択した値であり、ACT に有利な選択バイアスを含む。未知エピソードでの予測力は未検証である。

実機のサーボ追従の診断

教師指令 action[t]と観測 state[t+lag]を比較すると、アーム全体の最良ラグは+3 フレーム（約 0.20 秒）だった。shoulder_pan、shoulder_lift、wrist_flex、wrist_roll は+3、elbow_flex は+4 フレームで最良だった。

関節	最適ラグ	補正前→補正後 MAE
shoulder_pan	+3	1.977° → 0.843°
shoulder_lift	+3	2.374° → 1.208°
elbow_flex	+4	3.001° → 1.675°
wrist_flex	+3	1.150° → 0.880°
wrist_roll	+3	0.417° → 0.328°

実機追従ラグ約 0.20 秒と ACT 予測の先行約 0.60 秒は異なる現象であり、前者だけで後者を説明できない。いずれも位置・速度系列から推定した実効ラグであって、同期バグの存在を立証するものではない。

6. 映像による確認と限界

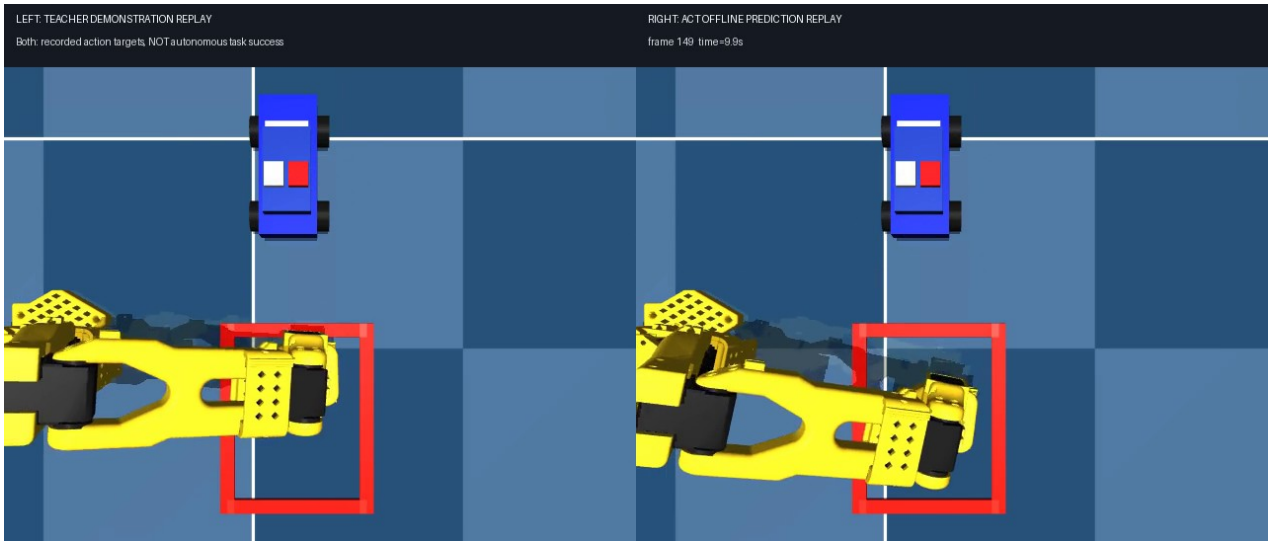


図 2　比較動画の相対 frame 149（Episode 2 frame 219）。左：教師指令再生、右：ACT のオフライン予測再生（同一初期姿勢）。

元の暫定関節マッピングを使用した 20 秒の比較動画では、両者のアームがそれぞれ異なる姿勢へ進むことを確認した。実機の画像ではミニカーが Goal 領域へ移動したが、MuJoCo 内のミニカーは表示専用なので移動しない。

固定画像 ACT 実行の結果

6,000 ステップの ACT に実写画像を 1 枚固定して入力し、仮想関節状態だけを各ステップ更新して 30 秒間実行すると、最初の約 1〜2 秒に数度の変位があり、その後はほぼ静止した。使用した画像は dataset index 1218（Episode 2 frame 318）。45 フレーム試験では推論 45 回・関節範囲クリッピング 0 回。固定画像条件のため視覚情報の追従効果は評価できず、ミニカーの押し込みも再現していない。

主な制約

- MuJoCo 上のミニカーと Goal 枠は静的表示で、衝突と物体移動がない。
- ACT 実行試験の画像は録画済み実写フレームで固定しており、視覚閉ループ制御ではない。
- 関節符号・ゼロ位置の厳密な実機校正は未完了。
- 模倣精度の評価は学習エピソード上であり、汎化・タスク成功率を示さない。

7. 結論と次の研究課題

本研究では、実機データセットの収集、ACT 学習、MuJoCo 内の関節駆動、教師軌道と ACT 予測軌道の同条件比較、時刻特性の定量診断を一連のパイプラインとして実装できた。一方、ACT によるミニカー Goal 到達の自律再現には至っていない。

次の実装優先度

1. カメラ・関節の校正：実機と MuJoCo の座標・符号・ゼロ位置を再検証。

2. 物体物理：ミニカーの接触・移動、Goal 判定、初期条件を実装。

3. 視覚閉ループ：MuJoCo レンダ画像をポリシーへ入力し、画像分布差を評価。

4. 評価の分離：未学習エピソードと複数ロールアウトで成功率を測る。

再現性と公開に関する方針

GitHub にはシミュレーション・解析コード、暫定マッピング、結果サマリー、比較映像、再現手順を整理する。実機の未公開録画データ、学習済み重み、巨大キャッシュ、個人情報、COM ポート操作コードは掲載しない。MuJoCo のモデル/mesh は原則として元の配布元から取得する。

引用文献・利用技術

Zhao, T. Z. et al. (2023). Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware. https://arxiv.org/abs/2304.13705

Todorov, E. et al. (2012). MuJoCo: A physics engine for model-based control. IROS. DOI: 10.1109/IROS.2012.6386109

LeRobot ACT: https://github.com/huggingface/lerobot

SO-101 MJCF: https://github.com/TheRobotStudio/SO-ARM100/tree/main/Simulation/SO101

MuJoCo: https://mujoco.readthedocs.io/

本報告の数値はローカルに保存された summary.txt、チェックポイント比較ログ、時間ずれ監査ログ、MuJoCo 生成映像に基づく。収録時の未公開データセット本体は添付していない。

Appendix A. ACT 学習条件と実行履歴

保存済み train_config.json・config.json・training_step.json と PowerShell 実行履歴に基づき、採用した No-VAE モデルの学習設定を整理した。VAE ありの別実験で記録された損失は No-VAE モデルの学習曲線とは扱わない。

項目	値・根拠
学習方式	LeRobot v0.6.1 ACT / No-VAE（保存設定で確認）
代表モデル	checkpoint 006000（6,000 steps。10,000 まで再開学習）
ACT 構成	chunk_size=20、ResNet18、dim_model=128、Encoder 2 層、Decoder 1 層
オフライン評価の設定	n_action_steps=1（チャンク先頭アクションを毎フレーム評価）
モデルの保存設定	n_action_steps=20、use_vae=False、KLWeight=10（No-VAE のため KL 項は不使用）
学習バッチサイズ	1（train_config.json・training_step.json で確認）
学習 Optimizer	AdamW：LR=1e-5、weight_decay=1e-4、betas=(0.9,0.999)、eps=1e-8、grad_clip_norm=10
学習のその他設定	seed=1000、log_freq=100、wandb.enable=False、scheduler は null/未設定
学習 GPU・所要時間	未確認（GPU・連続実行時間を推測しない）
学習 Loss の記録	採用 No-VAE の Loss 推移は未発見。VAE あり別実験の 2,000〜5,000 step のログは存在
初期学習の系統	No-VAE fresh 5,000 step：resume=False、checkpoint_path なし、policy.pretrained_path なし
学習再開の実行履歴	fresh No-VAE 005000 を config_path に指定し resume=true で 5,000→10,000 step
データ評価分割	eval_split=0.2、image_transforms.enable=False。LeRobot v0.6.1 は各タスクの末尾 20%を評価用へ分離（単一タスク 10 件なら 8/2）

データセットの eval_split=0.2 は評価用エピソードの分割設定である。LeRobot v0.6.1 ではタスクごとに末尾の ceil(n×0.2)エピソードを評価用とするため、全 10 エピソードが同一タスクなら Episode 0〜7 を学習用、8〜9 を評価用に分割する。実データのタスク別内訳と分割ログは本提出物では未検証。No-VAE の Loss 履歴、実学習時間、GPU の正確な利用記録は未確認。